

# Processos Estocásticos

Gabriela Alcaide - 14746492

Universidade de São Paulo - USP

2024

# O que são Processos Estocásticos?

Processos que envolvem uma família de variáveis aleatórias indexadas por índices (que representam tempo, por exemplo).

## **Exemplos:**

- 1) Lançar um dado equiprovável algumas vezes ao longo do tempo.
- 2) Medir o nível de colesterol ao longo do tempo.

Processos Estocásticos podem ser representados como gráficos, conforme segue.

# O que são Processos Estocásticos?

- Os vértices são os estados possíveis da variável;
- As arestas representam a alteração de índice ("passagem do tempo");
- Os pesos das arestas representam as probabilidades.

Dessa forma, podemos utilizar matrizes para representar o Processo:

$$a_{ij} = Pr(X_{t+1} = j | X_t = i)$$

Ou seja, o valor na posição  $ij$  é a probabilidade de que, estando no estado da linha  $i$ , chegue-se ao estado da coluna  $j$ .

# Cadeia de Markov

Processo Estocástico em que uma observação depende apenas da observação imediatamente anterior.

O passado remoto não é relevante.

$$Pr(X_{n+1} = x | X_1, \dots, X_n) = Pr(X_{n+1} = x | X_n)$$

Ou seja, a probabilidade de uma observação dadas todas as anteriores é igual a probabilidade dessa observação dada apenas a imediatamente anterior.

# Hidden Markov Model

Considere a família de variáveis aleatórias  $X$ , que funciona conforme uma Cadeia de Markov. As observações dessa família  $X$  são desconhecidas.

Considere também uma família de variáveis aleatórias  $Y$ , que dependem de  $X$ , e cujas observações são conhecidas.

## **Problema:**

Dada certa sequência de observações de  $Y$ , qual a sequência mais provável de  $X$ ?

# Hidde Markov Model

- 1) Calcular a probabilidade de cada sequência de observações de  $X$ .

$$Pr(X = X_1, \dots, X_n | Y = Y_1, \dots, Y_n)$$

- 2) Aplicar o Teorema de Bayes.

$$Pr(X = X_1, \dots, X_n | Y = Y_1, \dots, Y_n) = \frac{Pr(Y|X) \times P(X)}{P(Y)}$$

$$Pr(X = X_1, \dots, X_n | Y = Y_1, \dots, Y_n) \propto Pr(Y|X) \times P(X)$$

- 3) Como  $Y_t$  depende apenas do humor em  $X_t$ :

$$Pr(Y|X) = Pr(Y_1|X_1) * \dots * Pr(Y_n|X_n)$$

# Hidden Markov Model

4) Como  $X$  segue a Cadeia de Markov,  $X_t$  depende apenas de  $X_{t-1}$ :

$$Pr(X) = \prod Pr(X_t|X_{t-1})$$

5) Com 3 e 4, temos:

$$\prod Pr(Y_t|X_t) * Pr(X_t|X_{t-1})$$

6) Encontrar a sequência de observações de  $X$  que maximiza a expressão:

$$\arg \max_X \prod Pr(Y_t|X_t) * Pr(X_t|X_{t-1})$$

# Markov Decision Process

Considere um conjunto de estados  $S$ , um conjunto de ações  $A$  e um conjunto de recompensas  $R$ , todos finitos. Considere ainda que as variáveis referentes aos estados e às ações dependem apenas das observações imediatamente anteriores.

A cada momento  $t = 0, 1, \dots$ , o agente recebe uma representação do estado  $S_t$ . Com base nesse estado, o agente toma uma decisão  $A_t$ . Daí, forma-se o par estado-ação  $(S_t, A_t)$ .

O tempo é, então, incrementado para  $t + 1$ , e o estado vai para  $S_{t+1}$ . Nesse ponto, o agente recebe a recompensa  $R_{t+1}$ , que se refere à ação  $A_t$ .



# Markov Decision Process

Esse processo corresponde a uma função  $f$  tal que

$$f(S_t, A_t) = R_{t+1}$$

A trajetória desse processo sequencial é representada como:

$$S_0, A_0, R_1, S_1, A_1, R_2, S_2, A_2, R_3, \dots$$

# Markov Decision Process

## Problema:

Qual a probabilidade de obter o estado  $s'$  com recompensa  $r$ , por tomar a ação  $a$  no estado  $s$ ?

Sejam  $s'$  e  $s \in S$ ,  $r \in R$  e  $a \in A(s)$  - conjunto de ações que podem ser tomadas a partir do estado  $s$ .

$$Pr(s', r | s, a) = Pr(S_t = s', R_t = r | S_{t-1} = s, A_{t-1} = a)$$

# Gaussian Process Regression

Um **Processo Gaussiano** pode ser compreendido pelo seguinte raciocínio:

- Uma amostra de distribuição normal representa um número distribuído ao redor de sua média;
- A distribuição normal pode ser generalizada, para representar um vetor de números (distribuição normal multivariada);
- Se esse vetor de números for infinito, tem-se um Processo Gaussiano.

# Gaussian Process Regression

Considere um conjunto  $Y$  de pontos conhecidos.

## Problema:

Com base nesses pontos conhecidos, qual função tem maior probabilidade de ter gerado esses pontos?

Duas informações são relevantes para essa solução:

- 1) A distribuição de probabilidade das funções é dada por Processos Gaussianos.
- 2) É possível adaptar a distribuição a novos pontos, calculando a probabilidade de uma função dada uma nova observação  $y_i$ :

$$Pr(f|y_i) = \frac{Pr(f, y_i)}{Pr(y_i)}$$

# Gaussian Process Regression

Unindo essas informações, pode-se calcular e adaptar a distribuição aos pontos  $Y$  observados.

Quando é necessário prever uma única função, ela será a média das funções previstas, que é parte do Processo Gaussiano.

# Kallman Filter

Considere que a movimentação de um corpo é observada.

Para estimar sua posição em determinado momento, são utilizadas duas abordagens: utilizar um radar (estimativa por medição - em) ou realizar os cálculos com base em medidas relativas, como a velocidade do corpo (estimativa por estado - ee).

Em ambos os casos, as estimativas podem ser descritas como distribuições normais, cujas médias são as posições mais prováveis para o corpo, em cada abordagem.

## **Problema:**

Como obter a estimativa ótima para a posição do corpo, com base nas estimativas obtidas?

# Kallman Filter

Para resolver essa questão, alguns passos devem ser seguidos, tomando  $E$  como erro:

1) Calcular o Kallman Gain:

$$KG = \frac{E_{ee}}{E_{ee} + E_{em}}$$

2) Estimativa ótima para o tempo  $t$ :

$$Est_t = Est_{t-1} + KG * (em - Est_{t-1})$$

Essa estimativa será tomada como nova estimativa de estado para o tempo  $t$ .

# Kallman Filter

3) Erro da nova estimativa para o tempo  $t$ :

$$(1 - KG) * E_{t-1}$$

Quanto mais vezes o Kallman Filter é usado, menor o erro da estimação, e melhor a predição.

Trata-se de um Processo Markoviano, pois necessita apenas do erro e da estimativa imediatamente anteriores.



# Particle Filter

Considere que a movimentação de um corpo é observada.

Para estimar sua posição em determinado momento, são utilizadas duas abordagens: utilizar um sensor que está no corpo ou realizar os cálculos com base em medidas relativas.

Em ambos os casos, as estimativas não podem ser descritas como distribuições normais.

## **Problema:**

Como obter a estimativa ótima para a posição e direção do corpo, com base nas estimativas obtidas?

Sabe-se que, inicialmente, qualquer posição e direção são igualmente prováveis.

# Particle Filter

Para resolver essa questão, alguns passos devem ser seguidos:

- 1) Gerar pontos conforme uma distribuição aleatória uniforme e salvá-los no filtro como uma estimativa possível.
- 2) Obter a informação do sensor do corpo real e, comparando com as informações dos sensores das estimativas possíveis, determinar a probabilidade delas.
- 3) Gerar novos pontos conforme a nova distribuição (que não é mais uniforme).
- 4) Conforme o robô se move, mover as estimativas possíveis de acordo.
- 5) Voltar ao passo 2.

# Bibliografia

UNIVESP. *Modelos Probabilísticos para Computação - Aula 06 - Processos Estocásticos (1)*. YouTube. 2017. URL: <https://www.youtube.com/watch?v=EX0dPzDHTU>.

UNIVESP. *Modelos Probabilísticos para Computação - Aula 07 - Processos Estocásticos (2)*. YouTube. 2017. URL: <https://www.youtube.com/watch?v=G8bBIMfKPC4>.

Normaliz Nerd. *Hidden Markov Model Clearly Explained! Part - 5*. YouTube. 2020. URL: <https://www.youtube.com/watch?v=RWkHJnFj5rY>.

Deeplizard. *Markov Decision Processes (MDPs) - Structuring a Reinforcement Learning Problem*. YouTube. 2018. URL: <https://www.youtube.com/watch?v=my207WNoeyA>.

# Bibliografia

Parelos. *Easy introduction to gaussian process regression (uncertainty models)*. YouTube. 2021. URL:  
<https://www.youtube.com/watch?v=iDzaoEwd0N0>.

Augmented AI. *Kalman Filter for Beginners*. YouTube. 2016. URL:  
<https://www.youtube.com/watch?v=bm3cwEP2nUot=34s>.

MATLAB. *Understanding the Particle Filter | | Autonomous Navigation, Part 2*. YouTube. 2020. URL:  
<https://www.youtube.com/watch?v=NrzmHyerBU>.